

视觉定位与感知-HW3

516021910700 郭远帆

1.

设：

$$\Phi_1 = \mathbf{x}^\wedge = \begin{bmatrix} 0 & -x_3 & x_2 \\ x_3 & 0 & -x_1 \\ -x_2 & x_1 & 0 \end{bmatrix}$$

$$\Phi_2 = \mathbf{y}^\wedge = \begin{bmatrix} 0 & -y_3 & y_2 \\ y_3 & 0 & -y_1 \\ -y_2 & y_1 & 0 \end{bmatrix}$$

$$\Phi_3 = \mathbf{z}^\wedge = \begin{bmatrix} 0 & -z_3 & z_2 \\ z_3 & 0 & -z_1 \\ -z_2 & z_1 & 0 \end{bmatrix}$$

首先验证封闭性：

$$\begin{aligned} \Phi_1 \Phi_2 - \Phi_2 \Phi_1 &= \begin{bmatrix} -x_2 y_2 - x_3 y_3 & x_2 y_1 & x_3 y_1 \\ x_1 y_2 & -x_3 y_3 - x_1 y_1 & x_3 y_2 \\ x_1 y_3 & x_2 y_3 & -x_2 y_2 - x_1 y_1 \end{bmatrix} \\ &\quad - \begin{bmatrix} -x_2 y_2 - x_3 y_3 & x_1 y_2 & x_1 y_3 \\ x_2 y_1 & -x_3 y_3 - x_1 y_1 & x_2 y_3 \\ x_3 y_1 & x_3 y_2 & -x_2 y_2 - x_1 y_1 \end{bmatrix} \\ &= \begin{bmatrix} 0 & x_2 y_1 - x_1 y_2 & x_3 y_1 - x_1 y_3 \\ x_1 y_2 - x_2 y_1 & 0 & x_3 y_2 - x_2 y_3 \\ x_1 y_3 - x_3 y_1 & x_2 y_3 - x_3 y_2 & 0 \end{bmatrix} \end{aligned}$$

可以看到结果也是反对称矩阵，封闭性得以验证。

接下来验证双线性：

$$\begin{aligned} [a\Phi_1 + b\Phi_2, \Phi_3] &= (a\Phi_1 + b\Phi_2)\Phi_3 - \Phi_3(a\Phi_1 + b\Phi_2) \\ &= a(\Phi_1\Phi_3 - \Phi_3\Phi_1) + b(\Phi_2\Phi_3 - \Phi_3\Phi_2) \\ &= a[\Phi_1, \Phi_3] + b[\Phi_2, \Phi_3] \\ [\Phi_3, a\Phi_1 + b\Phi_2] &= \Phi_3(a\Phi_1 + b\Phi_2) - (a\Phi_1 + b\Phi_2)\Phi_3 \\ &= a(\Phi_3\Phi_1 - \Phi_1\Phi_3) + b(\Phi_3\Phi_2 - \Phi_2\Phi_3) \\ &= a[\Phi_3, \Phi_1] + b[\Phi_3, \Phi_2] \end{aligned}$$

双线性得以验证。

接下来验证自反性。

$$\begin{aligned} [\Phi_1, \Phi_1] &= \begin{bmatrix} -x_2 x_2 - x_3 x_3 & x_2 x_1 & x_3 x_1 \\ x_1 x_2 & -x_3 x_3 - x_1 x_1 & x_3 x_2 \\ x_1 x_3 & x_2 x_3 & -x_2 x_2 - x_1 x_1 \end{bmatrix} \\ &\quad - \begin{bmatrix} -x_2 x_2 - x_3 x_3 & x_1 x_2 & x_1 x_3 \\ x_2 x_1 & -x_3 x_3 - x_1 x_1 & x_2 x_3 \\ x_3 x_1 & x_3 x_2 & -x_2 x_2 - x_1 x_1 \end{bmatrix} \\ &= \mathbf{0} \end{aligned}$$

自反性得以验证。

最后验证雅可比等价性。

由之前的性质，该运算在向量形式上可以看作叉积(观察 $\phi_1\phi_2 - \phi_2\phi_1$ 结果可知复原的向量是原向量叉积的结果)

而在向量叉积中，有如下性质:

$$\vec{x} \times (\vec{y} \times \vec{z}) + \vec{z} \times (\vec{x} \times \vec{y}) + \vec{y} \times (\vec{z} \times \vec{x}) = 0$$

该性质与雅可比等价性一致，由此一致性可以得到雅可比等价性的验证，因此不再展开。

以上，验证了该李代数。实际上，该李代数即是三维向量 \mathbf{R}^3 上定义的叉积。

2.

对三维向量 x ，我们假设其四元数表示为 $[0, x, y, z]^T$ ，其中 x, y, z 为其三个坐标轴的坐标。根据四元数的运算法则，对于单位四元数 q ，有:

$$q^{-1} = \frac{q^*}{||q||^2} = q^*$$

$$\text{有 } q^* = [q_w, -q_x, -q_y, -q_z]^T$$

由四元数的乘法计算公式，有:

$$\begin{aligned} q \otimes x^\sim &= -q_x x - q_y y - q_z z \\ &\quad + (q_w x + q_y z - q_z y)i \\ &\quad + (q_w y - q_x z + q_z x)j \\ &\quad + (q_w z + q_x y - q_y x)k \end{aligned}$$

要证明该变换是旋转变换，需要证明变换后的四元数 x^\sim 的实部为0。根据四元数的乘法计算公式,有:

$$\begin{aligned} \text{Re}\{q \otimes x^\sim \otimes q^*\} &= q_w(-q_x x - q_y y - q_z z) \\ &\quad + q_x(q_w x + q_y z - q_z y) \\ &\quad + q_y(q_w y - q_x z + q_z x) \\ &\quad + q_z(q_w z + q_x y - q_y x) \end{aligned}$$

最终所有项均可两两消去，有 $\text{Re}\{q \otimes x^\sim \otimes q^*\} = 0$,故该变换可以表示为旋转变换。利用乘法公式对虚部进行同样的操作，有:

$$\begin{aligned} \text{I}\{q \otimes x^\sim \otimes q^*\} &= q_x(q_x x + q_y y + q_z z) \\ &\quad + q_w(q_w x + q_y z - q_z y) \\ &\quad + (-q_z)(q_w y - q_x z + q_z x) \\ &\quad + q_y(q_w z + q_x y - q_y x) \end{aligned}$$

$$\text{解得最终结果为: } \text{I}\{q \otimes x^\sim \otimes q^*\} = (1 - 2q_y^2 - 2q_z^2)x + (2q_x q_y - 2q_w q_z)y + (2q_x q_z + 2q_w q_y)z$$

这实际上对应旋转矩阵 R 的第一行。对其它两个虚数部分进行同样的计算，可以得到最终旋转矩阵:

$$R = \begin{bmatrix} 1 - 2q_y^2 - 2q_z^2 & 2q_x q_y - 2q_w q_z & 2q_x q_z + 2q_w q_y \\ 2q_x q_y + 2q_w q_z & 1 - 2q_x^2 - 2q_z^2 & 2q_y q_z - 2q_w q_x \\ 2q_x q_z - 2q_w q_y & 2q_y q_z + 2q_w q_x & 1 - 2q_x^2 - 2q_y^2 \end{bmatrix}$$

3.

实验原理:

设旋转矩阵 \mathbf{R} 以及其扰动 $\Delta\mathbf{R}$, 设扰动的李代数为 $\boldsymbol{\theta}$, 有:

$$\frac{\partial(\mathbf{R}\mathbf{x})}{\partial\boldsymbol{\theta}} = -(\mathbf{R}\mathbf{x})^\wedge$$

$\boldsymbol{\theta}$ 为 $\Delta\mathbf{R}$ 的李代数表示, 将 $\boldsymbol{\theta}$ 表示为旋转向量的形式: $\boldsymbol{\theta} = \theta\mathbf{n}$, 其中 \mathbf{n} 为旋转轴 (单位向量), θ 为旋转角。由此定义参数更新 $\mathbf{R} := \mathbf{R} \oplus \boldsymbol{\theta}$ 如下:

$$\mathbf{R} \oplus \boldsymbol{\theta} = \mathbf{R}(\mathbf{I} + [\boldsymbol{\theta}]^\wedge)$$

其中符号 $^\wedge$ 为向量的反对称矩阵表示(或者表示为 $[\boldsymbol{\theta}]_\times$)。严格上来说, 上式为近似公式, 参数更新也可用下式表达:

$$\mathbf{R} \oplus \boldsymbol{\theta} = \mathbf{R}(\cos\theta\mathbf{I} + (1 - \cos\theta)\boldsymbol{\theta}\boldsymbol{\theta}^T + \sin\theta[\boldsymbol{\theta}]^\wedge)$$

如果采用四元数来代表旋转, 那么参数更新的定义 $\mathbf{q} := \mathbf{q} \oplus \boldsymbol{\theta}$:

$$\mathbf{q} \oplus \boldsymbol{\theta} = \mathbf{q} \otimes \left\{ \cos\frac{\theta}{2}, \mathbf{n}\sin\frac{\theta}{2} \right\}$$

当迭代到 θ 足够小时, 采用近似公式表示:

$$\mathbf{q} \oplus \boldsymbol{\theta} = \mathbf{q} \otimes \left\{ 1, \frac{\boldsymbol{\theta}}{2} \right\}$$

这里的乘符号是四元数的乘法。

根据高斯牛顿法的思想, 每一轮迭代的近似优化目标为:

$$\min \sum_i^3 (\bar{\mathbf{y}}_i - \mathbf{R} \exp([\Delta\boldsymbol{\theta}]_\times) \bar{\mathbf{x}}_i)^2$$

其中 $\Delta\boldsymbol{\theta}$ 即扰动 $\Delta\mathbf{R}$ 的李代数表示。根据扰动模型, 近似为求解此方程:

$$\min \sum_i^3 (\bar{\mathbf{y}}_i - \mathbf{R}\bar{\mathbf{x}}_i + [\mathbf{R}\mathbf{x}_i]_\times \Delta\boldsymbol{\theta})^2$$

定义 $\mathbf{z}_i = \bar{\mathbf{y}}_i - \mathbf{R}\bar{\mathbf{x}}_i$, $\mathbf{J}_i = [\mathbf{R}\mathbf{x}_i]_\times$, 上式关于 $\Delta\boldsymbol{\theta}$ 导数为 0 可得:

$$\sum_i^3 \mathbf{J}_i^T \mathbf{J}_i \Delta\boldsymbol{\theta} = - \sum_i^3 \mathbf{J}_i^T \mathbf{z}_i$$

求解此方程, 得:

$$\Delta\boldsymbol{\theta} = - \left(\sum_i^3 \mathbf{J}_i^T \mathbf{J}_i \right)^{-1} \left(\sum_i^3 \mathbf{J}_i^T \mathbf{z}_i \right)$$

根据之前的参数更新定义, 更新 \mathbf{R} (或者 \mathbf{q}) 即可。最后对于更新后的 \mathbf{R} 需要保证其正交性, 对于 \mathbf{q} 需要保证其单位性。采用 SVD 分解保证 \mathbf{R} 的正交性, 采用归一化保证 \mathbf{q} 的单位性即可。

除此之外, 参考《视觉 SLAM 十四讲》, 3D 位姿估计问题还有一种 SVD 解法, 其原理如

下:

定义两组点的质心如下:

$$\vec{y}_g = \frac{1}{3} \sum_{i=1}^3 \vec{y}_i, \vec{x}_g = \frac{1}{3} \sum_{i=1}^3 \vec{x}_i$$

然后得到这两组点的去质心坐标:

$$\vec{q}_i = \vec{y}_i - \vec{y}_g, \vec{p}_i = \vec{x}_i - \vec{x}_g$$

定义矩阵 **W**:

$$\mathbf{W} = \sum_{i=1}^3 \mathbf{q}_i \mathbf{p}_i^T$$

对 **W** 进行 SVD 分解, 得到:

$$\mathbf{W} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$$

然后可以解得 **R**:

$$\mathbf{R} = \mathbf{U} \mathbf{V}^T$$

该方法是一种几何的方法, 将多点的变换“浓缩”为质心之间的变换, 在样本数大的情况下其效果不一定比高斯牛顿法好, 但由于本次实验中样本点只有 3 个, 我们采用这个方法与高斯牛顿法进行对比。

实现关键思路:

代码实现通过 Matlab 语言, 以下为实现的关键思路:

基础模块实现:

1. 为了计算向量的反对称矩阵, 实现 $X = \text{skew}(x)$ 函数, 接受 3×1 向量 x 作为输入, 输出其反对称矩阵 X
2. 实现 $R = \text{q2r}(q)$ 以及 $q = \text{r2q}(R)$ 函数, 实现四元数到旋转矩阵的转换
3. 误差计算函数 $\text{target}(R, x, y)$ 计算目标函数
4. 实现 $q = \text{Qmult}(q1, q2)$ 实现四元数的乘法

基础模块实现后, 根据高斯牛顿法的迭代思想持续更新参数并记录误差即可。Matlab 对矩阵运算的支持相当完善, 代码语言与数学语言近似, 在此不再进行冗余的描述。

在本实验中分别实现了四元数表达方式、旋转矩阵表达方式下的高斯牛顿法, 其功能接近, 可用于验证计算是否正确。

实验结果与分析:

采用 SVD 方法得到的旋转矩阵为:

$$\mathbf{R}_m = \begin{bmatrix} 0.8660 & -0.3536 & 0.3536 \\ 0.3536 & 0.9330 & 0.0670 \\ -0.3536 & 0.0670 & 0.9330 \end{bmatrix}$$

给出的误差约为 2^{-31} , 在此基础上加入随机扰动项, 然后在不同扰动的情况下开始迭代, 观察扰动大小不同情况下的收敛速度如表 1(迭代 x 次项中为得到的误差)。

表 1 实验数据表

扰动大小	初始误差	迭代 2 次	迭代 5 次	迭代 10 次	迭代 20 次	迭代 50 次	迭代 100 次
0.01	1.21e-4	7.82e-6	7.78e-8	1.42e-15	2.32e-20	2.27e-31	8.51e-32
0.1	6.52	0.093	2.61e-4	1.1e-6	2.17e-12	2.27e-29	2.54e-32
1	7.13	0.014	2.42e-4	3.02e-7	5.52e-13	6.45e-30	4.22e-31
10	7.66	0.031	1.27e-4	1.81e-7	3.22e-13	1.51e-30	2.50e-32
随机正交基	10.31	0.85	0.013	8.81e-5	1.43e-10	1.15e-27	1.91e-31

随机正交基下的误差变换图:




图 1

可以看到，初始误差越大，收敛的速度也就较慢，然而无论如何，10 代之后已经有了相当可观的结果，迭代到 50 代已经接近最优解。

总结:

本实验中对高斯牛顿法在 3D-3D 位姿估计问题中的应用进行了实现，对比了不同初值情况下的高斯牛顿法收敛结果，并比较了 SVD 方法与高斯牛顿法的误差结果。在样本点较小的情况下，SVD 方法可以较快地得到精确的结果，但相比高斯牛顿法，计算开销较大。

本实验的代码由 Matlab 编写，实现了基于旋转矩阵和四元数表达的高斯牛顿法模型以及 SVD 求解方法。

感想和体会:

第三题是踩了不少的坑啊！由于理论知识不够扎实，对于李代数的扰动模型不熟悉，对于参数更新的不理解，一开始得到的结果千奇百怪。但也正因为如此，去查阅了各种资料，将高翔博士的《视觉 SLAM 十四讲》看了一遍又一遍，将老师的 PPT 温习了一遍又一遍，最后终于成功地分别实现了四元数表达的高斯牛顿法、旋转矩阵表达的高斯牛顿法，还把 SVD 方法（基于几何学）也实现了一遍，历时约两个星期，终于将这个问题解了出来。

感谢老师的指导和支持！SLAM 真的很有趣，本次作业相当精彩